

# Lista 2

---

## Zadanie 1

---

Niech  $B \in \{2, 3, 4, \dots\}$ . Pokażmy, że każda niezerowa liczba rzeczywista  $x$  ma jednoznaczne przedstawienie w postaci  $x = smB^c$ , gdzie  $s = \operatorname{sgn} x$ ,  $c \in \mathbb{Z}$ ,  $m \in [\frac{1}{B}, 1)$ .

Założmy nie wprost, że istnieją dwie różne reprezentacje takiej liczby  $x$  i oznaczmy je jako:

$$x = s_1 m_1 B^{c_1} = s_2 m_2 B^{c_2},$$

gdzie  $m_1, m_2 \in [\frac{1}{B}, 1)$  oraz  $c_1, c_2 \in \mathbb{Z}$ .

Przy czym  $s = s_1 = s_2$ . Mamy zatem:

$$s m_1 B^{c_1} = s m_2 B^{c_2}$$

$$m_1 B^{c_1} = m_2 B^{c_2}$$

$$\frac{m_1}{m_2} = \frac{B^{c_2}}{B^{c_1}}$$

$$\frac{m_1}{m_2} = B^{c_2 - c_1}$$

Rozpatrzmy przypadki:

$$1^\circ \ c_1 = c_2$$

Wtedy:

$$\frac{m_1}{m_2} = 1 \implies m_1 = m_2$$

Sprzeczność z założeniem o dwóch różnych reprezentacjach.

$$2^\circ \ c_1 > c_2 \implies c_2 - c_1 \leq -1$$

Czyli  $B^{c_2 - c_1} \leq \frac{1}{B}$ .

$$\frac{m_1}{m_2} = B^{c_2 - c_1} \leq \frac{1}{B}$$

$$m_1 \leq m_2 \frac{1}{B}$$

Z założenia  $m_2 < 1$ , więc otrzymujemy:

$$m_1 < \frac{1}{B}$$

A ponieważ  $m_1 \in [\frac{1}{B}, 1)$  to otrzymujemy sprzeczność.

$$3^\circ \ c_1 < c_2 \implies c_2 - c_1 \geq 1$$

Czyli  $B^{c_2-c_1} \geq B$ .

$$\frac{m_1}{m_2} = B^{c_2-c_1} \geq B$$

$$m_1 \geq Bm_2$$

Ponieważ  $m_2 \geq \frac{1}{B}$  otrzymujemy:

$$m_1 \geq 1$$

Sprzeczność, ponieważ  $m_1 \in [\frac{1}{B}, 1)$ .

## Zadanie 2

$m_{(2)}$	$m_{(10)}2^0$	$m_{(10)}2^{-1}$	$m_{(10)}2^1$
$\pm 0.1111$	$\pm \frac{15}{16}$	$\pm \frac{15}{32}$	$\pm \frac{15}{8}$
$\pm 0.1110$	$\pm \frac{14}{16}$	$\pm \frac{14}{32}$	$\pm \frac{14}{8}$
$\pm 0.1101$	$\pm \frac{13}{16}$	$\pm \frac{13}{32}$	$\pm \frac{13}{8}$
$\pm 0.1100$	$\pm \frac{12}{16}$	$\pm \frac{12}{32}$	$\pm \frac{12}{8}$
$\pm 0.1011$	$\pm \frac{11}{16}$	$\pm \frac{11}{32}$	$\pm \frac{11}{8}$
$\pm 0.1010$	$\pm \frac{10}{16}$	$\pm \frac{10}{32}$	$\pm \frac{10}{8}$
$\pm 0.1001$	$\pm \frac{9}{16}$	$\pm \frac{9}{32}$	$\pm \frac{9}{8}$
$\pm 0.1000$	$\pm \frac{8}{16}$	$\pm \frac{8}{32}$	$\pm \frac{8}{8}$

Najmniejszy przedział zawierający wszystkie te liczby to  $[-\frac{15}{8}, \frac{15}{8}]$

Rozkład liczb na osi w tym przedziale:



Zauważmy, że im większe (co do modułu) liczby, tym bardziej 'rozrzucone' są na osi OX, czyli tracimy

możliwość precyzyjnego zaprezentowania liczby. A dla liczb co modułu mniejszych od  $\frac{1}{4}$  tracimy możliwość reprezentacji (w przyjętym modelu).

## Zadanie 3

---

Niech

$x = sm2^c$ , gdzie  $s = \operatorname{sgn} x$ ,  $c \in \mathbb{Z}$ ,  $m \in [\frac{1}{2}, 1)$ ,

$rd(x) = sm_t^r 2^c$ , gdzie  $m_t^r \in [\frac{1}{2}, 1)$  oraz  $|m - m_t^r| \leq \frac{1}{2}2^{-t}$

Pokazać, że

$$\frac{|rd(x) - x|}{|x|} \leq 2^{-t}$$

Dowód:

$$\frac{|rd(x) - x|}{|x|} = \left| \frac{sm_t^r 2^c - sm 2^c}{sm 2^c} \right| = \left| \frac{m_t^r - m}{m} \right| =$$

$$\frac{|m - m_t^r|}{m} \leq \frac{1}{2}2^{-t} \frac{1}{m} \stackrel{(1)}{\leq} 2^{-t}$$

$$(1) m \in [\frac{1}{2}, 1) \implies \frac{1}{m} \in (1, 2]$$

## Zadanie 4

---

25 lutego 1991r. bateria American Patriot Missile nie zdołała wyśledzić oraz przechwycić nadlatującego irackiego pocisku. Jak się okazuje, śmierć 28 żołnierzy i zranienie kolejnych 100 osób spowodował błąd w obliczeniach.

Czas w zegarze komputera liczony był w dziesiątkach sekund (od rozpoczęcia pracy) i był reprezentowany liczbami całkowitymi. Do uzyskania czasu w sekundach ta liczba mnożona była przez  $\frac{1}{10}$  (operacja na liczbach zmiennoprzecinkowych). Ponieważ  $\frac{1}{10}$  ma nieskończone rozwinięcie w systemie binarnym, a rejestry w tym komputerze były 24-bitowe to każda taka operacja obarczona była małym błędem.

Do odpowiedniego przewidzenia, gdzie rakieta powinna się znajdować użyto funkcji korzystającej z jej prędkości oraz czasu, w którym ostatni raz została wykryta przez radar. Tamtego dnia system pracował około 100 godzin, co przekłada się na 0.34s błędu. Biorąc pod uwagę, że owy typ rakiety leci z prędkością  $1676 \frac{m}{s}$  to wykroczył poza monitorowany obszar.

## Zadanie 5

---

Diagram illustrating the IEEE 754 single-precision floating-point format (32 bits):

- Bit 31:** Sign (S) - Znak
- Bits 24-23:** Exponent (E) - Wykładnik
- Bits 16-15:** Mantissa (M) - Mantysa
- Bits 8-7:** Mantissa (M) - Mantysa
- Bits 0:** Mantissa (M) - Mantysa

$$\pm \mid 1 \mid m_2 \mid m_3 \mid \dots \mid m_b \mid \pm \mid c_1 \mid c_2 \mid \dots \mid c_{d-b-1}$$

Algorytm do obliczania wartości  $d := \sqrt{x^2 + y^2}$ :

```

u := x*x;
u := u + y*y;
d := sqrt(u)

```

Pokażmy, że przy zaproponowanym algorytmie może wystąpić zjawisko nadmiaru.

Niech  $X_{fl} = [-16, 16]$  oraz  $x = y = 8$ , stosując algorytm:

```

u := 8*8      // (1)
u := 64 + 8*8 // (2)
d := sqrt(128)

```

Jak widzimy, w miejscach (1) oraz (2) algorytmu wystąpiło zjawisko nadmiaru, mimo że  $d = \sqrt{128} = 8\sqrt{2} \approx 11,3 \in X_{fl}$ .

Niech  $M = \max(|x|, |y|) \neq 0$

Wtedy:

$$\sqrt{x^2 + y^2} = M\sqrt{\frac{x^2}{M^2} + \frac{y^2}{M^2}} = M\sqrt{\left(\frac{x}{M}\right)^2 + \left(\frac{y}{M}\right)^2} \leq \sqrt{2}\max(|x|, |y|) \in X_{fl}$$

Algorytm unikający zjawiska nadmiaru:

```

u := min(x,y)/max(x,y);      \ \ u <= 1
u := 1 + u*u;
u := abs(max(x,y)) + sqrt(u);

```

Długość euklidesowa wektora (w  $\mathbb{R}^n$ ):

$$\|x\| = \sqrt{x \cdot x} = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}}$$

Niech  $M = \max(|x_1|, |x_2|, \dots, |x_n|)$ , oraz wiedząc, że  $\max(|x_1|, |x_2|, \dots, |x_n|)\sqrt{n} \in X_{fl}$

$$\begin{aligned} \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} &= M\sqrt{\frac{x_1^2}{M^2} + \frac{x_2^2}{M^2} + \dots + \frac{x_n^2}{M^2}} = \\ M\sqrt{\left(\frac{x_1}{M}\right)^2 + \left(\frac{x_2}{M}\right)^2 + \dots + \left(\frac{x_n}{M}\right)^2} &\leq M\sqrt{n} = \max(|x_1|, |x_2|, \dots, |x_n|)\sqrt{n} \end{aligned}$$

Algorytm:

```

m := max(x[1], x[2], ..., x[n]);
s := 0;
For i = 1, 2, ... n
    t := x[i]/m;
    s := s + t*t;
s := sqrt(s);
d := abs(m) * s;

```

## Zadanie 8

---

$$f(x) = 4040 \frac{\sqrt{x^{11} + 1} - 1}{x^{11}}$$

Z poprzedniej listy wiemy, iż już  $f(0.001)$  daje niewiarygodny wynik. Dzieje się tak ze względu na zjawisko utraty cyfr znaczących.

Dla małych  $x$ ,  $\sqrt{x^{11} + 1} - 1$  interpretowany jest jako 0, dlatego też dla całego wyrażenia otrzymujemy 0.

Wzór możemy przekształcić:

$$\begin{aligned} f(x) &= 4040 \frac{\sqrt{x^{11} + 1} - 1}{x^{11}} = 4040 \frac{(\sqrt{x^{11} + 1} - 1)(\sqrt{x^{11} + 1} + 1)}{x^{11}(\sqrt{x^{11} + 1} + 1)} = \\ &= \frac{4040}{\sqrt{x^{11} + 1} + 1} \end{aligned}$$

Tym samym pozbywając się zjawiska utraty cyfr znaczących dla małych  $x$ .

tags: an1